



UNIVERSIDAD NACIONAL DE ASUNCIÓN

Facultad de Ciencias Exactas y Naturales

Departamento de Estadística

Maestría en Estadística

**Caracterización de la sequía y evaluación de la
aridificación en Paraguay durante el periodo 2000-2023,
en un contexto de calentamiento global**

Hernán J. Vargas Ojeda

Orientador: Prf. Dr. Gonzalo Martin Vicente

Co-Orientador: Prf. Dr. Gustavo Ignacio Rivas M.

Tesis presentada a la Facultad de Ciencias Exactas y Naturales, Universidad Nacional de Asunción, como requisito para la obtención del Grado de Magíster en Estadística

SAN LORENZO - PARAGUAY

Marzo - 2026

Ficha Catalográfica del Trabajo de Tesis

Datos Internacionales de Catalogación en la Publicación (CIP)
DE LA BIBLIOTECA E INTERNET DE LA FACEN - UNA

Vargas Ojeda, Hernán Javier

Caracterización de la sequía y evaluación de la aridificación en Paraguay durante el periodo 2000-2023, en un contexto de calentamiento global / Hernán J. Vargas Ojeda. – San Lorenzo: Universidad Nacional de Asunción. Facultad de Ciencias Exactas y Naturales, 2026.

60 h.; 30 cm.

Incluye referencias bibliográficas.

Tesis (Magíster en Estadística). – Universidad Nacional de Asunción. Facultad de Ciencias Exactas y Naturales, 2026.

1.Tesis de postgrado – UNA 2.Sequía 3.SPEI 4.Aridificación
5.Panel data model 6.Calentamiento Global 7.Paraguay

519.5/V297a

Dedicatoria

A mi familia...

Agradecimientos

En primer lugar, deseo expresar mi más profundo agradecimiento a mis orientadores, por su invaluable guía y paciencia infinita. Sus agudas observaciones y su constante apoyo fueron fundamentales para dar forma y dirección a esta investigación.

Agradezco a los miembros de la mesa examinadora de Coordinación de Postgrado e Investigación en Estadística, Departamento de Estadística, FACEN - UNA, por aceptar evaluar este trabajo y por sus valiosas sugerencias que sin duda lo enriquecerán.

Mi gratitud a la Facultad de Ciencias Exactas y Naturales de la Universidad Nacional de Asunción, y en especial al Departamento de Estadística, por brindarme el espacio y los recursos para mi formación de posgrado.

Quisiera extender un agradecimiento especial a la Dirección de Meteorología e Hidrología (DMH) por facilitar el acceso a los datos crudos que constituyen la base de este estudio.

A mis compañeros de la Maestría en Estadística, gracias por las largas jornadas de estudio, las discusiones enriquecedoras y el compañerismo que hicieron este camino más ameno.

A mis padres, María Asunción de Rodríguez y Mario Rodríguez M., por su amor incondicional y por inculcarme el valor del esfuerzo y la educación. A mi pareja, Adriana Viveros González, por su paciencia infinita, su aliento en los momentos difíciles y por ser mi principal apoyo. Sin ustedes, este logro no habría sido posible.

Resumen

Palabras clave: sequía, aridificación, SPEI, datos de panel, calentamiento global.

Abstract

Keywords: drought, climate change, SPEI, panel data, time series.

Índice

Índice de cuadros

Índice de figuras

Capítulo 1

Introducción

La aridez es una característica estructural, climatológica y permanente de una región con niveles bajos de precipitación, la sequía a diferencia de la aridez, es temporal y transitoria, en donde la disponibilidad de agua se sitúa por debajo de los requerimientos normales de un área. Como afirma ? (?), estos fenómenos comprometen de manera directa la seguridad alimentaria al afectar directamente a la agricultura, el acceso al recurso hídrico y la estabilidad macroeconómica.

Mientras que la sequía es una anomalía transitoria, la aridificación representa un cambio estructural a largo plazo hacia un clima permanentemente más seco. Eventos recurrentes o prolongados de sequía empujan a un ecosistema más allá de su límite de recuperación, consolidando un clima y un suelo más áridos. De acuerdo con informes recientes de las Naciones Unidas (? , ?), la frecuencia y duración de estos eventos extremos de sequía se han incrementado aproximadamente un 30% a nivel global desde el año 2000.

La temperatura desempeña un rol fundamental en la dinámica de estos fenómenos, según ? (?), el incremento de las temperaturas globales provocado por el cambio climático acelera la tasa de evaporación del agua del suelo y la transpiración de las plantas . El Grupo Intergubernamental de Expertos sobre el Cambio Climático (IPCC) sostiene de manera concluyente que el calentamiento del sistema climático global es inequívoco.

En el contexto sudamericano, particularmente en la Cuenca del Plata, la sequía se manifestó con severidad a partir de mediados de 2019, dando inicio a una sequía extrema y prolongada que se extendió hasta finales de 2022. Este evento hidrometeorológico provocó un estiaje histórico en los ríos Paraguay y Paraná, afectando de manera sostenida a sectores estratégicos como la agricultura, la navegación comercial fluvial y la generación de energía hidroeléctrica (? , ?).

La República del Paraguay presenta una alta vulnerabilidad ante estos escenarios debido a su condición de país mediterráneo y a la fuerte dependencia estructural de su economía respecto al sector agropecuario. Dentro del espectro de amenazas climáticas, la sequía representa el fenómeno con mayor potencial de impacto económico negativo para el país (? , ?).

1.1. Planteamiento del problema

La literatura científica a nivel nacional ha aportado elementos significativos para comprender las manifestaciones locales del cambio climático. Diversos estudios han documentado tendencias ascendentes y estadísticamente significativas en las temperaturas medias anuales en gran parte del territorio nacional (? , ?), así como alteraciones en los regímenes de precipitación y en la frecuencia de eventos climáticos extremos (? , ?).

El problema metodológico e investigativo central radica en la ausencia en el contexto nacional de una métrica unificada que integre la precipitación y la temperatura de manera simultánea para evaluar las sequías de forma integral, así como un modelo estadístico que cuantifique las tendencias dinámicas para identificar trayectorias de cambio a largo plazo que nos permitan identificar procesos de aridificación.

En un escenario de cambio climático, evaluar las sequías basándose exclusivamente en las anomalías de precipitación y omitir la influencia de la temperatura genera una subestimación del déficit hídrico real y del proceso de aridificación progresiva de los ecosistemas.

Un análisis que introduce esta tesis es, tener en cuenta los efectos de la temperatura no solo los del calentamiento global, sino también las fluctuaciones estacionales de la temperatura (verano, invierno, primavera, otoño), que pueden influir significativamente en la dinámica de la sequía. Históricamente, el régimen climático de Paraguay se ha caracterizado por veranos húmedos e inviernos relativamente más secos; sin embargo, esta configuración estacional podría estar experimentando modificaciones estructurales como consecuencia del calentamiento global y un proceso de aridificación progresiva inducida por la recurrencias de eventos de sequías extremas.

A partir de esta brecha de conocimiento, se formulan las siguientes preguntas de investigación:

1. ¿Cuál es la disponibilidad y estructura de los datos oficiales para evaluar la sequía y la aridificación en Paraguay durante el período 2000–2023, considerando

tanto la precipitación como la temperatura?

2. ¿Qué metodología es adecuada para medir las sequías y la aridificación en un contexto de calentamiento global?
3. ¿Cómo se ha caracterizado la sequía en Paraguay durante el período 2000–2023 al ser evaluada mediante una métrica sensible al calentamiento global?
4. ¿La sequía se manifiesta de forma homogénea en todo el territorio nacional?
5. ¿Existen procesos de aridificación durante el período 2000–2023, son espacialmente homogéneos estos procesos?, ¿Son homogéneos estos procesos de aridificación en las diferentes estaciones climáticas anuales?
6. Considerando las sequías, ¿es estadísticamente significativo el efecto del calentamiento global en Paraguay durante el período 2000–2023?

1.2. Justificación de la investigación

El desarrollo de este trabajo se justifica bajo tres dimensiones analíticas:

- **Dimensión Socioeconómica:** La cuantificación precisa de dinámicas de la sequía provee evidencia empírica clave para el diseño de políticas de adaptación sectorial, optimizando la gestión de riesgos en un sector agropecuario altamente vulnerable (?, ?, ?).
- **Dimensión Científica:** Supera las limitaciones de los análisis climáticos univariados al proveer una caracterización sistemática de la sequía en Paraguay basada en un análisis que integra la temperatura como un factor condicionante, mejorando su comprensión en el marco del calentamiento global.
- **Dimensión Metodológica:** Introduce el cálculo de un índice integrado sensible al calentamiento global y un modelado de datos de panel no explorado en el caso nacional, estableciendo un marco de análisis cuantitativo controlando la heterogeneidad no observada de las estaciones meteorológicas terrestres.

1.3. Hipótesis

Para guiar el análisis empírico, se plantean las siguientes hipótesis de investigación:

H1: La sequía en Paraguay presenta una tendencia temporal durante el período 2000–2023 que no es uniforme a lo largo del año, sino que muestra dinámicas divergentes entre las distintas estaciones climáticas.

H2: La tendencia temporal de la sequía exhibe un comportamiento espacialmente heterogéneo, no se manifiesta de manera uniforme en todo el territorio nacional, en el período 2000–2023.

H3: Tener en cuenta el comportamiento de las temperaturas en el estudio de las sequías revela una incidencia real en la evolución de los patrones de sequía, lo que evidencia el impacto significativo del calentamiento global.

1.4. Objetivos de la investigación

1.4.1. Objetivo general

Ajustar un modelo de datos de panel (panel data model) que integre variables sensibles al calentamiento global para conocer la evolución temporal de la sequía en Paraguay durante el período 2000–2023, considerando simultáneamente las variaciones entre regiones geográficas y estaciones climáticas.

1.4.2. Objetivos específicos

1. Recopilar, depurar y estructurar una base de datos en formato de panel que integre los registros diarios de precipitación y temperatura de las estaciones meteorológicas oficiales del Paraguay, aplicando criterios rigurosos de control de calidad y selección muestral.
2. Calcular las series temporales mensuales de un índice estandarizado de balance hídrico (SPEI) que permitan medir la sequía en un contexto de calentamiento global durante el período bajo estudio.
3. Desarrollar un análisis descriptivo de la sequía para caracterizar los patrones de estacionales, frecuencia, intensidad, duración y extensión espacial de la sequía a nivel nacional.
4. Estimar e interpretar los parámetros del modelo de datos de panel ajustado sobre el SPEI para cuantificar las tendencias de la sequía y evaluar su comportamiento en las distintas estaciones climáticas, así como su heterogeneidad espacial.

5. Probar que el impacto del calentamiento global en la sequía durante el período 2000–2023 en Paraguay es estadísticamente significativo.

Capítulo 2

Marco Teórico

2.1. Antecedentes de investigación sobre la sequía en Paraguay

El estudio de la sequía mediante índices de balance hídrico multivariados es un estándar internacional, su aplicación instrumental en Paraguay ha sido históricamente limitada. No obstante, las investigaciones nacionales previas proveen las bases científicas para examinar las dinámicas térmicas locales.

Un aporte referencial es el de Chávez (?, ?), quien mediante pruebas estadísticas no paramétricas aplicadas a series históricas de temperatura (periodo 1960–2018), confirmó tendencias de calentamiento sistemáticas y estadísticamente significativas en la mayor parte de las estaciones meteorológicas terrestres del país. De forma complementaria, Pasten (?, ?) identificó un incremento significativo en la frecuencia de días y noches cálidas a nivel nacional.

Asimismo, Grassi (?, ?) determinó que la tasa de calentamiento observada en el Paraguay durante las últimas décadas supera el promedio mundial. Un hallazgo relevante de este autor es que, a pesar de registrarse incrementos leves en las medias de precipitación anual, la frecuencia y los impactos de las sequías extremas han aumentado significativamente durante el siglo XXI. Esto sugiere que las fluctuaciones térmicas positivas desempeñan un rol dominante en la intensificación del déficit hídrico por encima de la dinámica de las precipitaciones. Por último, las proyecciones de la Comisión Económica para América Latina y el Caribe (?, ?) confirman que la persistencia de estas dinámicas inducirá choques de oferta desfavorables en la estabilidad económica nacional.

2.2. La Sequía: Características

La sequía es un fenómeno de desarrollo lento y acumulativo. Sus efectos se manifiestan de manera gradual, lo que dificulta la determinación precisa de su inicio y final, pudiendo persistir durante años incluso después de que las condiciones meteorológicas hayan retornado a la normalidad (?, ?).

De acuerdo con la literatura especializada, las cuatro características fundamentales para el análisis de la sequía son: la intensidad, la duración, la frecuencia y la extensión espacial (?, ?).

El análisis conjunto de estas cuatro dimensiones resulta esencial para una evaluación integral del riesgo y la formulación de estrategias de mitigación efectivas.

2.3. Clasificación de la sequía

La comunidad científica ha desarrollado un marco conceptual estándar que clasifica la sequía en cuatro tipos principales, entendidos como una secuencia de propagación de impactos (?, ?):

1. Sequía meteorológica: punto de partida del fenómeno y se define estrictamente por un déficit de precipitación durante un período prolongado en comparación con la media histórica registrada en una región.
2. Sequía agrícola: Se manifiesta cuando el déficit de lluvia se propaga induciendo un déficit de humedad en la zona radicular del suelo, afectando la germinación, el crecimiento y el rendimiento de los cultivos y pasturas.
3. Sequía hidrológica: Refiere a la disminución significativa de los niveles y caudales en las fuentes de agua superficiales y subterráneas, tales como ríos, lagos, embalses y acuíferos.
4. Sequía socioeconómica: Ocurre cuando la escasez física del recurso hídrico, derivada de las fases anteriores, afecta de manera directa la oferta y la demanda de bienes y servicios económicos.

La presente investigación se centra en la caracterización y modelización de la *sequía meteorológica*. Esta elección se fundamenta en que representa el indicador primario y precursor de todos los demás impactos hidrológicos, agrícolas y socioeconómicos, convirtiéndose en el componente crítico para cualquier sistema de detección

temprana. La sequía meteorológica se puede calcular a partir de datos disponibles en la red de estaciones terrestres, evitando los requerimientos de datos biofísicos complejos en gran parte no disponibles en el contexto nacional que demandan las otras clasificaciones.

2.4. Sequía en Paraguay: impulsores y consecuencias

Las causas de las sequías no se conocen con precisión absoluta, pero se han identificado una serie de factores naturales y otros productos de la actividad humana que contribuyen a su ocurrencia e intensidad.

Al igual que otros países de la región, el régimen pluviométrico de Paraguay se encuentra modulado por fenómenos climáticos de gran escala. El principal motor de la variabilidad interanual es El Niño-Oscilación del Sur (ENSO), un patrón de calentamiento y enfriamiento anómalo de las aguas superficiales del Océano Pacífico Ecuatorial. Otros patrones de variabilidad climática a nivel hemisférico, como la Oscilación Decadal del Pacífico (PDO) y la Oscilación Antártica (AAO), influyen en la regularidad de las precipitaciones, aunque sus dinámicas operan en escalas de tiempo más prolongadas y complejas (? , ?).

El calentamiento global actúa como un factor crítico de intensificación. El incremento sostenido de las temperaturas eleva la evapotranspiración potencial (ETP), exacerbando la severidad de las sequías bajo un mecanismo conocido en la literatura como olas de calor o hotter droughts en inglés (? , ?). Según ? (?) Este proceso fue determinante en la reciente sequía extrema (2019-2022) registrada en la Cuenca del Plata, donde las altas temperaturas extremaron el déficit hídrico preexistente provocado por la fase de La Niña.

La quema de combustible fósil, la deforestación, la explotación agrícola intensiva y la expansión urbana son algunas de las actividades humanas que impulsan las sequías (? , ?).

Dada la estructura productiva de su economía y su posición geográfica, Paraguay presenta una alta susceptibilidad ante las consecuencias de la sequía. Estos impactos se manifiestan de manera transversal en los siguientes sectores clave:

- Sector agropecuario: La sequía agrícola reduce drásticamente el rendimiento de los cultivos de renta (como la soja y el maíz), disminuye la receptividad de las pasturas y puede inducir tasas de mortandad ganadera significativas, traducéndose en pérdidas económicas millonarias (? , ?).

- **Navegación fluvial:** El estiaje prolongado de los ríos Paraguay y Paraná, consecuencia directa de la sequía hidrológica, afecta la principal vía de importación y exportación comercial de la nación. La reducción del calado operativo de las barcazas incrementa sustancialmente los costos logísticos y debilita la competitividad del comercio exterior.
- **Generación de energía hidroeléctrica:** Paraguay depende casi en su totalidad de la hidroelectricidad generada por las represas binacionales de Itaipú y Yacyretá. La sequía hidrológica reduce el caudal afluente, comprometiendo la capacidad de generación y disminuyendo los ingresos estatales percibidos por la exportación de excedentes energéticos.
- **Aspectos sociales y ambientales:** La escasez de agua afecta de manera directa a las comunidades rurales y suburbanas vulnerables, limitando su acceso al agua potable y comprometiendo la agricultura de subsistencia. Adicionalmente, las condiciones prolongadas de sequedad y calor elevan exponencialmente el riesgo de propagación de incendios forestales, con la consecuente degradación de ecosistemas y pérdida de biodiversidad.

2.5. Sequía y el proceso de aridificación

La sequía puede actuar como un factor desencadenante o un acelerador crítico del proceso de aridificación, cuando una región sufre una sequía severa y prolongada la energía solar calienta directamente el suelo y el aire circundante, este aumento de temperatura local incrementa la demanda atmosférica de agua (la evapotranspiración potencial o PET que mide el SPEI). Una atmósfera más cálida y seca reduce la probabilidad de lluvias locales creando un círculo vicioso que estabiliza las condiciones secas y acelera la transición hacia un régimen climático estructuralmente más árido. Bajo las condiciones del calentamiento global, las sequías actúan hoy como la "punta de lanza" de la aridificación.

2.6. Consistencia y completitud en series temporales climatológicas

Un desafío recurrente en la modelización climatológica es la presencia de registros faltantes. El tratamiento inapropiado de la falta de datos mediante la eliminación siste-

mática de periodos observacionales introduce un sesgo que disminuye sustancialmente el poder estadístico de los modelos y altera el cálculo de acumulaciones temporales consecutivas esenciales para los índices de sequía.

De acuerdo con las directrices metodológicas de la Organización Meteorológica Mundial (?), la imputación de huecos cortos en series temporales es una práctica estandarizada y necesaria para asegurar la homogeneidad y consistencia de los datos. El tratamiento de registros faltantes en esta investigación se fundamenta teóricamente en la preservación de la estructura de autocorrelación de las series continuas. Para variables con una alta inercia térmica temporal, como la temperatura, se emplean interpolaciones lineales sobre ventanas temporales restringidas. En el caso de variables intermitentes y asimétricas, como la precipitación, la imputación se restringe a evaluaciones contextuales directas de vecindad temporal. Al limitar de manera estricta el proceso de imputación a huecos de duración ultra-corta (1 a 2 días), se evita la inserción de sesgo o variabilidad artificial, garantizando la consistencia analítica requerida para el posterior cálculo multiescalar de los índices de sequía.

2.7. Cuantificación de la sequía meteorológica: Los índices SPI y SPEI

Dada la naturaleza compleja y de desarrollo acumulativo de la sequía, su monitoreo y modelización rigurosa requieren el uso de indicadores cuantitativos estandarizados. Estos índices sintetizan las fluctuaciones climáticas instrumentales en un único valor numérico, permitiendo comparar la severidad espacial y temporal de las anomalías independientemente de la climatología local.

2.7.1. El índice de precipitación estandarizada (SPI)

El Índice de Precipitación Estandarizada (SPI), desarrollado por McKee, Doesken y Kleist (?), es uno de los indicadores más implementados globalmente. El SPI parte de la premisa matemática de que el déficit acumulativo de precipitación representa el principal factor detrás de las condiciones de sequía.

Su procedimiento metodológico consiste en ajustar los registros históricos de precipitación acumulada para una escala temporal seleccionada (por ejemplo, 3, 6 o 12 meses) a una función de distribución de probabilidad teórica, típicamente la distribución Gamma. Posteriormente, las probabilidades acumuladas resultantes se transfor-

man mediante la inversa de la función de distribución normal estándar, produciendo un índice normalizado (Z-score) con media cero y varianza unitaria. Los valores negativos indican condiciones más secas de lo normal y los valores positivos condiciones húmedas. Su gran ventaja radica en su flexibilidad multiescalar y simplicidad operacional, al requerir únicamente registros de precipitación.

A pesar de su utilidad regulatoria, el SPI exhibe una limitación conceptual crítica en escenarios de cambio climático: ignora sistemáticamente la influencia de las anomalías de temperatura. El calentamiento global altera no solo los regímenes de precipitación, sino que incrementa de forma directa la demanda evaporativa de la atmósfera, un factor físico determinante en el balance hídrico del suelo. La evapotranspiración potencial (ETP) define la pérdida máxima de agua que una superficie vegetal experimentaría si la disponibilidad hídrica fuera ilimitada. Temperaturas más elevadas conducen a una ETP incremental, acelerando la pérdida de humedad de los suelos y la vegetación. Por consiguiente, omitir la dinámica de la ETP puede resultar en una subestimación sustancial de la severidad de la sequía, especialmente durante eventos de olas de calor persistentes (? , ?).

2.7.2. El índice de precipitación-evapotranspiración estandarizado (SPEI)

Para resolver las limitaciones conceptuales del SPI ante el incremento térmico global, Vicente-Serrano, Beguería y López-Moreno (? , ?) diseñaron el Índice de Precipitación-Evapotranspiración Estandarizado (SPEI). El SPEI preserva las propiedades matemáticas y la flexibilidad del SPI, pero fundamenta su cálculo en el balance hídrico climático mensual (D_i), definido como la diferencia simple entre la precipitación (P_i) y la evapotranspiración potencial estimada (ETP_i):

$$D_i = P_i - ETP_i \quad (2.1)$$

El cálculo del índice acumula estas diferencias mensuales en diferentes escalas de tiempo históricas. Debido a que el balance hídrico puede tomar valores negativos, se recurre a la distribución Log-Logística de tres parámetros para ajustar las series temporales, ofreciendo una flexibilidad superior a la distribución Gamma de dos parámetros del SPI. Finalmente, se realiza el proceso de estandarización normal clásico para obtener los valores del SPEI (Z-score), permitiendo una clasificación objetiva de la intensidad de las anomalías hídricas (Cuadro 2.1).

Cuadro 2.1: Clasificación de las condiciones de sequía y humedad según los valores del Índice SPEI.

Valor del SPEI	Categoría
2.00 o más	Extremadamente Húmedo
1.50 a 1.99	Severamente Húmedo
1.00 a 1.49	Moderadamente Húmedo
-0.99 a 0.99	Condiciones Normales
-1.00 a -1.49	Sequía Moderada
-1.50 a -1.99	Sequía Severa
-2.00 o menos	Sequía Extrema

2.8. Acumulación del balance hídrico en múltiples escalas

El déficit hídrico no genera impactos inmediatos homogéneos sobre los sistemas biofísicos y socioeconómicos, sino que actúa bajo dinámicas temporales multiescales. En consecuencia, la serie temporal del balance hídrico mensual se acumuló en diferentes escalas de tiempo temporales k (? , ?):

- SPEI a 3 meses (SPEI-3): Representa condiciones de balance a corto plazo, útil para caracterizar anomalías de humedad en la capa superficial del suelo asociadas al inicio de la sequía agrícola.
- SPEI a 6 meses (SPEI-6): Actúa como una escala intermedia y puente entre las anomalías meteorológicas rápidas y los impactos de escala hidrológica en caudales menores. Se seleccionó como la variable dependiente de análisis de la presente tesis por su relevancia integral para capturar tanto impactos agrícolas como las fases tempranas de sequías hidrológicas en Paraguay.
- SPEI a 12 meses (SPEI-12): Mide variaciones a largo plazo asociadas a las reservas en acuíferos, embalses y sistemas fluviales de mayor envergadura.

2.9. Fundamentos del agrupamiento no supervisado (clustering) para regionalización geográfica de la sequía

Las divisiones político-administrativas o fisiográficas tradicionales (Región Oriental y Región Occidental) no siempre se corresponden de manera exacta con los patrones meteorológicos y de balance hídrico dinámicos. Para resolver el problema de la variabilidad espacial de la sequía de manera objetiva vamos a utilizar los datos reales del SPEI-6 de cada estación meteorológica para agruparlas en regiones geográficas homogéneas, mediante un algoritmo de agrupamiento no supervisado.

Por consiguiente, el aprendizaje estadístico no supervisado (unsupervised learning) proporciona un marco analítico riguroso para agrupar las estaciones meteorológicas basándose exclusivamente en la variabilidad temporal y covarianza de sus series históricas de sequía.

2.9.1. Algoritmo de agrupamiento jerárquico aglomerativo

El Agrupamiento Jerárquico Aglomerativo (HAC, por sus siglas en inglés) es una técnica de partición espacial iterativa que opera de forma ascendente. El algoritmo inicia asignando a cada estación meteorológica individual su propio grupo (clúster) y, de forma sucesiva, procede a fusionar los dos grupos más similares en cada iteración hasta que todas las entidades se integran en una estructura de árbol única conocida como dendrograma.

Este método de agrupamiento es óptimo para datos climáticos que operan bajo estructuras anidadas y continuas. El dendrograma permite a los climatólogos inspeccionar la jerarquía y cercanía de las subparticiones a diferentes niveles de escala, una propiedad física que los métodos planos o no jerárquicos como K-Means omiten por completo (?, ?).

Para dirigir de manera óptima las fusiones de los grupos en cada etapa y garantizar la homogeneidad interna, se implementa el criterio de enlace de Ward (Ward's minimum variance method). Este método busca minimizar de manera iterativa el incremento en la suma de los cuadrados de las distancias intra-grupo. El método de Ward (?, ?) es ampliamente reconocido en la literatura meteorológica y climatológica como el estimador más eficiente para la regionalización de variables continuas. Esto asegura que las estaciones dentro de cada clúster tengan series de sequía (SPEI-6) sumamente

homogéneas y que los límites de los clústeres tiendan a ser esféricos y geográficamente compactos (? , ?).

La disimilitud o distancia temporal entre dos entidades X y Y se cuantifica mediante la distancia euclídea clásica calculada sobre la totalidad de sus observaciones a lo largo de la serie histórica:

$$d(X, Y) = \sqrt{\sum_{t=1}^T (X_t - Y_t)^2} \quad (2.2)$$

Donde T es el número de periodos analizados en el panel. Dado que el SPEI es un índice normalizado con media cero y desviación estándar unitaria (Z-score) en cada estación, la distancia euclídea al cuadrado guarda una relación directa con el coeficiente de correlación de Pearson (r_{xy}) entre ambas series:

$$d^2(X, Y) = 2T(1 - r_{xy}) \quad (2.3)$$

Esta equivalencia matemática demuestra que agrupar estaciones meteorológicas minimizando la distancia euclídea equivale a maximizar la sincronía temporal de sus anomalías hídricas. De este modo, las estaciones pertenecientes a un mismo grupo ingresarán, persistirán y saldrán de los eventos de sequía de manera homogénea a lo largo del tiempo.

2.9.2. Determinación de la partición óptima mediante el coeficiente de silueta

A fin de evitar la discrecionalidad en el corte jerárquico del dendrograma y determinar un número óptimo de regiones geográficas, se utiliza el criterio formal del Ancho de Silueta Promedio (Average Silhouette Width). Este indicador evalúa de manera simultánea la cohesión interna de cada grupo frente a su separación respecto a los grupos vecinos.

Para cada estación individual i , se calcula su respectivo coeficiente de silueta $s(i)$ mediante la relación:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \quad (2.4)$$

Donde:

- $a(i)$ representa la distancia euclídea promedio entre la estación i y todos los demás miembros de su propio clúster.
- $b(i)$ representa la distancia promedio mínima entre la estación i y todos los miembros del clúster vecino más cercano.

El valor de $s(i)$ se halla estrictamente acotado en el intervalo $[-1, 1]$. Un valor cercano a 1 indica que la estación se encuentra correctamente asignada a su región y adecuadamente separada de las demás; un valor de 0 sugiere una zona de transición de baja diferenciación; y un valor negativo denota una clasificación incorrecta. El número óptimo de clústeres (k^*) se determina maximizando el ancho de silueta promedio de toda la red de estaciones M :

$$k^* = \arg \max_k \left(\frac{1}{M} \sum_{i=1}^M s(i) \right) \quad (2.5)$$

2.10. Fundamentos del modelado estadístico para datos de panel

El análisis de series temporales climatológicas observadas a través de redes terrestres de monitoreo presenta un desafío estadístico fundamental: la heterogeneidad espacial no observada. Cada estación meteorológica se halla condicionada por características físicas locales invariantes en el tiempo (como la altitud, la latitud, la topografía circundante o la geomorfología del suelo) que definen su nivel de base o intercepto climatológico.

Si estas características intrínsecas no se controlan de manera adecuada, sus efectos se combinan con la tendencia temporal estimada, induciendo sesgos severos por variable omitida. El análisis de datos de panel, o datos longitudinales, proporciona el marco de inferencia estadístico adecuado para aislar y resolver este problema (?). Al observar de manera repetida las mismas estaciones meteorológicas a lo largo del tiempo, este enfoque metodológico permite descomponer la varianza observada en dos componentes analíticos fundamentales: la variación entre unidades (variación *between*) y la variación a lo largo del tiempo para una misma unidad (variación *within*).

2.10.1. Modelos de efectos fijos (FE) vs. efectos aleatorios (RE)

Existen dos aproximaciones teóricas alternativas para especificar estadísticamente la heterogeneidad no observada de las estaciones:

Modelo de efectos fijos (FE)

Asume que los interceptos de cada unidad de análisis son fijos y específicos para cada estación i , representados por el parámetro α_i . El estimador de efectos fijos, también conocido como estimador "within", elimina las características invariantes en el

tiempo mediante la transformación por diferencias respecto a la media temporal de cada variable para cada unidad. La ventaja principal de este enfoque es que no requiere imponer el supuesto de ortogonalidad entre los efectos fijos específicos y las variables explicativas del modelo, controlando de manera robusta cualquier factor espacial invariante.

La especificación general del modelo FE se define como:

$$y_{it} = \alpha_i + \beta x_{it} + \varepsilon_{it} \quad (2.6)$$

Donde la transformación que elimina la heterogeneidad no observada opera como:

$$(y_{it} - \bar{y}_i) = \beta(x_{it} - \bar{x}_i) + (u_{it} - \bar{u}_i) \quad (2.7)$$

Modelo de efectos aleatorios (RE)

Este modelo asume que las características específicas invariantes de cada estación meteorológica, α_i , no actúan como parámetros fijos a estimar, sino como componentes aleatorios distribuidos de manera uniforme dentro del término de error compuesto del sistema. La hipótesis matemática fundamental del modelo de efectos aleatorios reside en la ortogonalidad o ausencia de correlación entre el componente aleatorio individual y los regresores del modelo. Si este supuesto de ortogonalidad se cumple, el estimador RE es estadísticamente más eficiente que el de efectos fijos, al utilizar de forma óptima tanto la variabilidad *within* como la variabilidad *between*.

La ecuación general se plantea de la siguiente forma:

$$y_{it} = \beta_0 + \beta x_{it} + (\alpha_i + \varepsilon_{it}) \quad (2.8)$$

Bajo la condición estricta de ortogonalidad:

$$Cov(\alpha_i, x_{it}) = 0 \quad (2.9)$$

2.10.2. Selección del modelo: El test de especificación de Hausman

La elección metodológica entre la aproximación de efectos fijos y efectos aleatorios no se determina de forma discrecional, sino que se fundamenta en la consistencia estadística del modelo RE. El test de especificación de Hausman (H, H) constituye la prueba estadística estándar para evaluar esta idoneidad.

Esta prueba contrasta sistemáticamente el vector de coeficientes estimados por el modelo FE (consistente bajo cualquier supuesto de correlación de los efectos individuales) frente al vector de coeficientes del modelo RE (consistente y eficiente únicamente bajo el supuesto de ortogonalidad). La hipótesis nula del test establece que no

existen diferencias sistemáticas significativas entre ambos estimadores:

$$H_0 : \hat{\beta}_{FE} = \hat{\beta}_{RE} \quad (2.10)$$

Si el p-valor calculado para la estadística de prueba es inferior al nivel de significancia establecido (típicamente $\alpha = 0,05$), se rechaza la hipótesis nula, indicando la presencia de correlación y la obligatoriedad metodológica de implementar la aproximación de efectos fijos para garantizar la consistencia de las estimaciones. Por el contrario, un p-valor elevado sugiere que las estimaciones del modelo de efectos aleatorios son robustas y preferibles debido a su mayor eficiencia.

2.10.3. Supuestos y limitaciones del modelo de panel

La validez metodológica del modelo de efectos aleatorios descansa sobre la verificación de los siguientes supuestos analíticos clave:

1. **Exogeneidad estricta:** Se asume que el componente de error idiosincrático, ε_{it} , no se encuentra correlacionado con las variables explicativas para ningún periodo temporal observacional. La consistencia del efecto aleatorio individual α_i respecto a las variables explicativas se valida mediante el test de Hausman.
2. **Homocedasticidad y no autocorrelación del error:** Supone que los errores idiosincráticos presentan una varianza constante e independiente a través de las observaciones temporales para una misma entidad. Debido a que las series climatológicas suelen exhibir autocorrelación y heterocedasticidad, este estudio aborda preventivamente dicha potencial desviación mediante la estimación de errores estándar robustos agrupados (clustered robust standard errors) a nivel de estación meteorológica. Esta técnica estadístico-analítica parametriza las matrices de covarianza para tolerar patrones arbitrarios de correlación y heterocedasticidad dentro de cada clúster individual, derivando p-valores y límites de confianza robustos para la inferencia de tendencias.

Cálculo teórico de los errores estándar agrupados

En el modelado de datos de panel, la presencia de correlación serial dentro de una misma estación meteorológica (autocorrelación) e idoneidades de varianza no constante (heterocedasticidad) invalida la inferencia basada en los errores

estándar ordinarios, tendiendo a subestimar significativamente la verdadera variabilidad de los estimadores. Para corregir este problema, se implementa el estimador de matriz de covarianza robusta agrupada por clústeres (estaciones), el cual generaliza el estimador robusto de White para permitir correlación arbitraria entre las observaciones de una misma entidad (?, ?).

Considérese el modelo lineal agrupado por estaciones (clústeres):

$$y_i = X_i\beta + u_i, \quad i = 1, 2, \dots, M \quad (2.11)$$

Donde M representa el número total de clústeres (estaciones meteorológicas seleccionadas), y_i es un vector de dimensión $T_i \times 1$ de la variable dependiente para la estación i , X_i es la matriz de regresores de dimensión $T_i \times K$, y u_i representa el vector de perturbaciones idiosincráticas de dimensión $T_i \times 1$.

El estimador de mínimos cuadrados ordinarios (o de efectos aleatorios tras la transformación de cuasi-diferenciación) se define como:

$$\hat{\beta} = \left(\sum_{i=1}^M X_i' X_i \right)^{-1} \sum_{i=1}^M X_i' y_i \quad (2.12)$$

La varianza asintótica de este estimador, condicionada en la matriz de regresores X , se modela bajo la estructura de varianza-covarianza tipo “sándwich”:

$$\text{Var}(\hat{\beta}|X) = (X'X)^{-1} B (X'X)^{-1} \quad (2.13)$$

Donde el núcleo interno B se define como la suma ponderada de las matrices de covarianza de los residuos para cada clúster independiente:

$$B = \sum_{i=1}^M X_i' \Omega_i X_i \quad (2.14)$$

En este esquema, $\Omega_i = E[u_i u_i' | X_i]$ es la matriz de varianza-covarianza de dimensión $T_i \times T_i$ específica para la estación i . El supuesto fundamental de este método es que las observaciones correspondientes a estaciones distintas son independientes entre sí ($E[u_i u_j' | X_i, X_j] = 0$ para todo $i \neq j$), permitiendo al mismo tiempo cualquier estructura de correlación y heterocedasticidad no paramétrica dentro de cada estación i .

Dado que Ω_i es desconocida, el estimador robusto agrupado sustituye esta matriz por el producto cruzado de los vectores de residuos muestrales ajustados para cada estación, $\hat{u}_i = y_i - X_i \hat{\beta}$:

$$\hat{\Omega}_i = \hat{u}_i \hat{u}_i' \quad (2.15)$$

De este modo, la estimación empírica de la matriz de varianza-covarianza de los coeficientes, $\widehat{\text{Var}}_{robust}(\hat{\beta})$, se calcula mediante la fórmula:

$$\widehat{\text{Var}}_{robust}(\hat{\beta}) = \left(\sum_{i=1}^M X_i' X_i \right)^{-1} \left(\sum_{i=1}^M X_i' \hat{u}_i \hat{u}_i' X_i \right) \left(\sum_{i=1}^M X_i' X_i \right)^{-1} \quad (2.16)$$

Para corregir los sesgos inherentes en muestras donde el número de clústeres M es finito, se aplica un factor de corrección de escala multiplicativo en la matriz de varianza-covarianza:

$$q = \left(\frac{M}{M-1} \right) \left(\frac{N-1}{N-K} \right) \quad (2.17)$$

Donde $N = \sum_{i=1}^M T_i$ representa el número total de observaciones mensuales del panel, y K es el número de parámetros estimados en el modelo. Los errores estándar agrupados por estación corresponden a la raíz cuadrada de los elementos de la diagonal principal de la matriz $q \cdot \widehat{\text{Var}}_{robust}(\hat{\beta})$.

Finalmente, una limitación inherente al marco de modelización propuesto reside en su especificación de tendencia lineal. El estimador asume una tasa de cambio constante en la anomalía hídrica a lo largo del periodo temporal estudiado, constituyendo una primera aproximación de tendencia a largo plazo que no captura dinámicas no lineales de escala decadal o cambios abruptos de régimen climático.

Capítulo 3

Materiales y Métodos

3.1. Diseño de la investigación

La presente investigación se enmarca en un enfoque cuantitativo de carácter longitudinal e inferencial. Es un estudio no experimental debido a que se basa en la observación e interpretación de datos históricos de variables climáticas tal como han ocurrido en su estado natural, sin manipulación deliberada por parte del investigador. Posee un carácter longitudinal debido a que la estructura de la base de datos sigue un diseño de panel, rastreando de forma sistemática el comportamiento de múltiples entidades (las estaciones meteorológicas) a lo largo de un período continuo de 24 años (2000–2023). Finalmente, es de carácter inferencial y analítico, ya que busca estimar parámetros de manera precisa para contrastar formalmente hipótesis respecto a las tendencias y variaciones espacio-temporales de la sequía en Paraguay, y no se limita a la mera descripción de patrones históricos.

3.2. Fuentes de datos y variables

Los datos primarios corresponden a los registros meteorológicos diarios provistos por la Dirección de Meteorología e Hidrología (DMH) de la Dirección Nacional de Aeronáutica Civil (DINAC)¹. Para cada estación meteorológica, se recopilieron las siguientes variables críticas diarias:

- Precipitación total diaria (en mm).
- Temperatura media diaria (en °C).

¹Consultado en el portal de Estaciones Meteorológicas Automáticas (EMAs): <https://www.meteorologia.gov.py/emas/> (último acceso: marzo, 2026).

- Temperatura máxima diaria (en °C).
- Temperatura mínima diaria (en °C).

De forma complementaria, se recopilaban los metadatos de las estaciones terrestres, incluyendo su nombre oficial, identificador (ID Estación), coordenadas geográficas de posicionamiento (latitud y longitud decimal) y su macroregión geográfica correspondiente (Región Oriental o Región Occidental).

3.3. Procedimiento de selección de muestra y limpieza de datos

Los registros instrumentales diarios originales presentaban diversos grados de completitud y calidad. Ciertas estaciones contaban con series prácticamente ininterrumpidas, mientras que otras exhibían pérdidas de información o vacíos temporales significativos. Con el propósito de construir una base de datos homogénea, consistente y estadísticamente representativa, se implementó un procedimiento de depuración y selección de muestra en dos fases.

3.3.1. Evaluación de datos faltantes

El análisis partió de una red inicial de 19 estaciones meteorológicas distribuidas a nivel nacional (detalladas en el Apéndice E). Para cada estación se cuantificó de forma sistemática la tasa de pérdida de datos diarios en el vector de variables críticas (precipitación y temperaturas) a lo largo de los 24 años de estudio.

3.3.2. Criterios de exclusión y selección muestra final

El proceso de refinamiento de la muestra se rigió por dos criterios estrictos de exclusión:

1. Criterio de continuidad temporal (Exclusión de vacíos largos): Se evaluaron los tramos continuos de datos faltantes. Bajo este criterio se decidió excluir la estación de Villarrica (VILL) debido a que, además de resultar geográficamente redundante con estaciones aledañas, presentaba anomalías instrumentales críticas caracterizadas por pérdidas continuas de datos superiores a los 30 días consecutivos, interrumpiendo la continuidad física de la serie.

2. Criterio de umbral de tolerancia cuantitativa: Sobre las 18 estaciones restantes, se aplicó un límite máximo admisible del 2.0 % de datos faltantes acumulados a nivel diario sobre el total de registros posibles del período 2000–2023. Aquellas estaciones que superaron este límite fueron descartadas.

Este procedimiento determinó la conformación de una muestra final de 11 estaciones meteorológicas de alta calidad sobre las cuales se llevó a cabo el modelado cuantitativo de la investigación. El Cuadro ?? resume los resultados de este proceso de depuración de la red original.

Cuadro 3.1: Resumen del proceso de selección de estaciones meteorológicas terrestres.

Región	Estación	% Faltante	Estado
Occidental	MCAL	0.78	Seleccionada
Occidental	PTOC	3.61	Descartada
Occidental	GBRU	0.73	Seleccionada
Occidental	PCOL	2.43	Descartada
Oriental	LUQUE	0.07	Seleccionada
Oriental	PILAR	0.82	Seleccionada
Oriental	MINGA	0.09	Seleccionada
Oriental	SGUA	2.86	Descartada
Oriental	CONC	0.07	Seleccionada
Oriental	PJC	0.32	Seleccionada
Oriental	SEST	1.67	Seleccionada
Oriental	SPED	3.59	Descartada
Oriental	CAAZ	0.59	Seleccionada
Oriental	CMEZA	1.44	Seleccionada
Oriental	COVIE	1.17	Seleccionada
Oriental	ENCAR	2.05	Descartada
Oriental	SJBA	4.44	Descartada
Oriental	VILL	1.35	Descartada

3.4. Tratamiento de datos faltantes (imputación)

Una vez seleccionada la red final de 11 estaciones meteorológicas, se abordó el tratamiento de los vacíos de información restantes, los cuales correspondían en su mayoría a fallas de transmisión puntuales de corta duración (1 a 2 días). Con el fin de

preservar la continuidad física de las observaciones diarias y el cálculo de agregaciones posteriores, se aplicó un método de imputación por capas diferenciado según las propiedades físicas de las variables:

- Variables térmicas (Media, Máxima y Mínima): Debido a la alta autocorrelación temporal intrínseca que caracteriza a las temperaturas diarias, se utilizó la interpolación lineal como estimador del valor faltante:

$$T_{\text{imputada},t} = T_{t-1} + \frac{T_{t+1} - T_{t-1}}{2} \quad (3.1)$$

Para mantener la rigurosidad científica de la interpolación y no inducir variabilidad artificial especulativa, se estableció un límite máximo de dos días consecutivos para la aplicación del estimador lineal.

- Variable pluviométrica (Precipitación): Dada la naturaleza física asimétrica, intermitente e intermitente de las lluvias, no es posible aplicar una interpolación temporal directa. Se utilizó un enfoque analítico condicional basado en la vecindad de los días adyacentes ($t - 1$ y $t + 1$):

1. Si ambos días adyacentes registraron precipitación nula ($P_{t-1} = 0$ y $P_{t+1} = 0$), el día faltante fue imputado con valor de cero ($P_t = 0$).
2. Si al menos uno de los días adyacentes presentó registro de lluvia, el valor faltante fue estimado mediante interpolación lineal simple para capturar la posible persistencia temporal del evento hidrometeorológico.

Los vacíos de datos con una duración continua igual o superior a tres días no fueron sujetos a ningún tipo de imputación y se preservaron como “valores perdidos” para salvaguardar la veracidad estadística de las series originales. Los impactos de este proceso sobre la completitud global de la base de datos se sintetizan en el Cuadro ??.

3.5. Agregación de datos y creación de la base mensual

Debido a que el modelado climático del balance hídrico y la dinámica de sequías se examina de forma estándar a escala mensual, el conjunto de datos diarios interpolados fue agregado a una frecuencia mensual para cada estación y año del período de estudio ($24 \text{ años} \times 12 \text{ meses} = 288$ observaciones potenciales por estación). Los descriptores mensuales se calcularon bajo los siguientes criterios de agregación física:

- lluvia_total: Sumatoria de precipitación diaria acumulada en el mes (mm/mes).

Cuadro 3.2: Resumen cuantitativo del impacto del proceso de depuración e imputación.

Métrica	Valor
Número de Estaciones	19 → 11
Número de Registros Diarios Iniciales (Base original)	157,275
Celdas Faltantes (Variables Críticas Iniciales)	7,788
Porcentaje de Datos Faltantes Iniciales (%)	1.23 %
Celdas Faltantes (Post-Selección de Estaciones)	3,061
Porcentaje de Faltantes (Post-Selección) (%)	0.73 %
Celdas Faltantes (Post-Imputación)	599
Porcentaje de Faltantes (Post-Imputación) (%)	0.14 %

- temp_media: Promedio aritmético de las observaciones diarias de temperatura media (°C).
- temp_max: Promedio aritmético de las observaciones de temperatura máxima diaria (°C).
- temp_min: Promedio aritmético de las observaciones de temperatura mínima diaria (°C).

Para garantizar la estabilidad y validez física de estas agregaciones climáticas, se aplicó el criterio estándar de tolerancia de datos faltantes recomendado por la Organización Meteorológica Mundial (?). Se estableció de manera estricta que un mes solo se considera válido para el cálculo de sus variables agregadas si cuenta con un mínimo de 25 días con registros diarios completos. Aquellos meses que no cumplieron con este umbral de consistencia temporal, producto de vacíos largos no imputables, fueron tratados estadísticamente como valores perdidos en el conjunto final de datos de panel. La aplicación de esta regla dio lugar a la exclusión de únicamente 14 observaciones mensuales de un universo total de 3,168 observaciones potenciales de panel, logrando una tasa de completitud estructural en la base de datos de panel final del 99.56 %.

3.6. Construcción de la variable dependiente: El índice SPEI

La variable dependiente del modelo de datos de panel es el Índice de Precipitación-Evapotranspiración Estandarizado (SPEI). Su obtención sistemática para cada una de

las 11 estaciones seleccionadas se programó e implementó en lenguaje Python utilizando algoritmos basados en la metodología estándar de Vicente-Serrano y cols. (2010) mediante la aplicación de las librerías científicas especializadas *scipy.stats* y *scipy.stats.pearson3*. El algoritmo operó secuencialmente bajo las siguientes etapas matemáticas:

3.6.1. Estimación de la evapotranspiración potencial (ETP)

Para estimar la demanda atmosférica de agua mensual sin requerir variables instrumentales de radiación o viento de difícil acceso, se programó el método empírico de Thornthwaite. La evapotranspiración potencial sin ajustar (en *mm/mes*) para un mes determinado se calcula mediante la fórmula:

$$ETP_{\text{sin ajustar}} = 16 \left(\frac{10 \cdot T_{\text{avg}}}{I} \right)^a \quad (3.2)$$

Donde T_{avg} representa la temperatura media agregada del mes en grados Celsius ($^{\circ}\text{C}$). Si la temperatura media del mes resulta inferior a 0°C , se le asigna de manera determinística un valor de 0.

El término I es el índice térmico de calor anual de la estación, el cual se deriva como la sumatoria de los 12 índices de calor mensuales (i_m) de un año promedio climatológico normal:

$$I = \sum_{m=1}^{12} i_m = \sum_{m=1}^{12} \left(\frac{T_{\text{avg},m}}{5} \right)^{1,514} \quad (3.3)$$

El exponente a es un coeficiente empírico no lineal que se parametriza matemáticamente en función del índice térmico de calor anual de la estación I , mediante el siguiente polinomio de tercer grado:

$$a = (6,75 \times 10^{-7})I^3 - (7,71 \times 10^{-5})I^2 + (1,792 \times 10^{-2})I + 0,49239 \quad (3.4)$$

Finalmente, la evapotranspiración potencial ajustada (ETP_{ajustada}) incorpora el efecto de la duración real de las horas de luz solar diarias según la latitud geográfica de cada estación y el mes calendario:

$$ETP_{\text{ajustada}} = ETP_{\text{sin ajustar}} \cdot K \quad (3.5)$$

Donde K representa el factor de corrección latitudinal mensual, tabulado estándar para el hemisferio sur en función de la latitud decimal y el número de días del mes.

3.6.2. Cálculo del balance hídrico climático

A partir de la serie mensual agregada de precipitación total (P_i) y de la serie mensual estimada de evapotranspiración potencial (ETP_i) para la estación en el mes i , se derivó la serie del balance hídrico simple (D_i), la cual representa la disponibilidad neta del recurso hídrico:

$$D_i = P_i - ETP_i \quad (3.6)$$

Si el balance resulta positivo ($D_i > 0$), la estación exhibe un superávit hídrico climático; si el balance resulta negativo ($D_i < 0$), denota un estado de déficit hídrico.

3.6.3. Balance hídrico en multiples escalas: Cálculo

Matemáticamente, para una escala de acumulación k , la sumatoria acumulada del balance hídrico D_i^k para el mes i se define de la siguiente manera:

$$D_i^k = \sum_{j=0}^{k-1} D_{i-j} \quad (3.7)$$

3.6.4. Ajuste a una distribución de probabilidad Pearson Tipo III

A diferencia del SPI clásico, que utiliza la distribución Gamma de dos parámetros, el balance hídrico acumulado D_i^k puede tomar valores negativos derivados del exceso de evapotranspiración sobre la lluvia, impidiendo el ajuste directo de distribuciones de probabilidad acotadas en cero. En consistencia con el entorno de cálculo de librerías en Python, se implementó el ajuste no paramétrico de las series acumuladas a la función de distribución teórica Pearson Tipo III (distribución Gamma de tres parámetros) por su alta estabilidad analítica frente a la asimetría y el comportamiento de colas gruesas en las colas de la distribución de balance de agua en Paraguay.

La función de densidad de probabilidad (PDF) para la distribución Pearson Tipo III se modela como:

$$f(x) = \frac{1}{|\beta|\Gamma(\alpha)} \left(\frac{x-\gamma}{\beta} \right)^{\alpha-1} e^{-\left(\frac{x-\gamma}{\beta}\right)} \quad (3.8)$$

Para un rango operativo de variables definido por $\beta > 0$ si $x > \gamma$, y $\beta < 0$ si $x < \gamma$. En esta ecuación:

- $\alpha > 0$ representa el parámetro de forma de la distribución (asociado a la asimetría).
- $\beta \neq 0$ representa el parámetro de escala física.

- γ representa el parámetro de localización que desplaza el origen de la distribución de probabilidad en el eje real.
- $\Gamma(\alpha)$ representa la función matemática Gamma.

La función de distribución acumulada (CDF), $P = F(x)$, se calcula a partir del ajuste de estos parámetros:

$$F(x) = \int_{\gamma}^x f(t) dt \quad (3.9)$$

3.6.5. Estandarización clásica normal

El paso final consiste en transformar las probabilidades acumuladas $P = F(x)$ a valores de desviación normal estándar (Z-scores) con media cero y desviación estándar unitaria. Para lograr una alta precisión numérica en el entorno computacional, se programó la aproximación racional analítica de Abramowitz y Stegun, la cual se ha convertido en un estándar de facto para la conversión de probabilidades acumuladas a valores Z en el ámbito de la estadística computacional.:

Para una probabilidad calculada de sequía P , donde $0 < P \leq 0,5$:

$$Z = W - \frac{c_0 + c_1 W + c_2 W^2}{1 + d_1 W + d_2 W^2 + d_3 W^3} \quad (3.10)$$

Donde la variable intermedia de escala W se calcula como:

$$W = \sqrt{-2 \ln(P)} \quad (3.11)$$

Si la probabilidad original acumulada resulta superior a un estado neutro ($P > 0,5$), se utiliza su complemento $1 - P$ en lugar de P para el cálculo del estimador intermedio W , y se invierte el signo algebraico del valor del índice de sequía resultante ($SPEI = -Z$).

Las constantes numéricas estándar de aproximación racional empleadas son:

$$\begin{array}{lll} c_0 = 2,515517 & c_1 = 0,802853 & c_2 = 0,010328 \\ d_1 = 1,432788 & d_2 = 0,189269 & d_3 = 0,001308 \end{array}$$

Este estimador numérico robusto asegura que las observaciones del SPEI-6 resultante de cada estación meteorológica sean comparables de manera directa a través de su evolución temporal y espacial.

3.7. Regionalización geográfica mediante agrupamiento no supervisado

Para resolver el problema planteado en la investigación respecto a la variabilidad espacial de la sequía, esta tesis propone superar la división geográfica clásica de Paraguay (Región Oriental y Región Occidental). A priori, la división administrativa e histórica de las macroregiones no necesariamente se corresponde con la dinámica física de los patrones climáticos reales de sequía.

Por consiguiente, se introduce un enfoque de aprendizaje estadístico no supervisado para agrupar las estaciones de monitoreo basándose estrictamente en el comportamiento dinámico y la covarianza de sus series temporales históricas mensuales de SPEI-6 a lo largo de los 24 años bajo estudio. El SPEI al ser una métrica estandarizada, permite comparar directamente la sincronidad temporal de las fluctuaciones hídricas entre estaciones, independientemente de sus niveles absolutos de precipitación o temperatura.

Dado que el objeto de estudio de esta tesis se centra en identificar tendencias de aridificación a largo plazo, resulta estadísticamente más consistente agrupar las estaciones meteorológicas por la sincronía de sus fluctuaciones hídricas temporales. Este enfoque remueve los efectos de nivel absoluto —los cuales ya han sido controlados matemáticamente en la construcción misma del SPEI-6— permitiendo que las subregiones resultantes del agrupamiento jerárquico representen la variabilidad hídrica y tendencias de aridificación homogéneas frente al calentamiento global.

3.7.1. Algoritmo de agrupamiento jerárquico aglomerativo

Se implementa la técnica de Agrupamiento Jerárquico Aglomerativo (HAC, por sus siglas en inglés). El algoritmo opera de abajo hacia arriba de forma iterativa: se parte de un estado inicial donde cada estación meteorológica individual constituye su propio grupo (clúster) y se procede a fusionar recursivamente los dos grupos más similares hasta que todos se consolidan en una única estructura de árbol jerárquica o dendrograma.

Para guiar la fusión óptima de grupos y preservar la homogeneidad interna de las agrupaciones resultantes, se implementa el criterio de enlace de Ward (Ward's minimum variance method). Este estimador busca minimizar de manera recursiva el incremento en la suma de los cuadrados de las distancias intra-grupo en cada fase de agrupación.

La distancia de disimilitud temporal entre dos estaciones meteorológicas X y Y se calcula a partir de la distancia euclídea simple aplicada sobre sus series completas de observaciones mensuales de SPEI-6:

$$d(X, Y) = \sqrt{\sum_{t=1}^T (X_t - Y_t)^2} \quad (3.12)$$

Donde $T = 288$ representa los meses de registro del panel. Dado que el SPEI es una métrica de desviación normal que ya se encuentra estandarizada a nivel de cada estación (Z -score), existe un fuerte correlato teórico que justifica esta distancia: la distancia euclídea al cuadrado es inversamente proporcional al coeficiente de correlación de Pearson (r_{xy}) que mide la sincronidad temporal de la sequía entre ambas estaciones:

$$d^2(X, Y) = 2T(1 - r_{xy}) \quad (3.13)$$

Consecuentemente, agrupar las estaciones minimizando la distancia euclídea equivale matemáticamente a consolidar agrupaciones geográficas que exhiben una alta sincronidad temporal en la ocurrencia, evolución y término de los eventos de sequía.

3.7.2. Determinación del número óptimo de grupos (clústeres)

A fin de evitar la discrecionalidad en la partición jerárquica del dendrograma y determinar una estructura espacial óptima de regiones de sequía a nivel nacional, se implementa el criterio formal del Ancho de Silueta Promedio (Average Silhouette Width). El análisis de silueta evalúa qué tan bien se encuentra agrupada cada estación evaluando de forma simultánea su distancia interna con los miembros de su propio grupo frente a su distancia externa con el clúster vecino más cercano.

Para cada estación i , se calcula su valor de silueta individual $s(i)$:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \quad (3.14)$$

Donde:

- $a(i)$ es el promedio de las distancias euclídeas de la estación i con todas las demás estaciones de su mismo grupo.
- $b(i)$ es el promedio de las distancias de la estación i con todas las estaciones del grupo vecino más cercano (el grupo que minimiza dicha distancia promedio).

El valor del coeficiente $s(i)$ se halla acotado en el intervalo $[-1, 1]$. Un valor cercano a 1 denota que la estación se encuentra perfectamente asignada a su región climática y alejada de clústeres adyacentes; un valor cercano a 0 sugiere una zona de

transición de baja diferenciación; y un valor negativo denota un error en el agrupamiento. El número óptimo de regiones climatológicas (k^*) se selecciona maximizando el Ancho de Silueta Promedio de toda la red de estaciones:

$$k^* = \arg \max_k \left(\frac{1}{M} \sum_{i=1}^M s(i) \right) \quad (3.15)$$

Donde $M = 11$ representa el número de estaciones seleccionadas. El algoritmo de optimización se programa e implementa en Python mediante el uso de la librería de minería de datos *scikit-learn*. Las características de las regiones óptimas halladas mediante esta técnica reemplazarán el uso de la variable regional dicotómica clásica en el modelado estadístico subsiguiente de la investigación.

3.8. Modelo estadístico

Para cuantificar las tendencias temporales de la sequía e identificar procesos de aridificación y variaciones estructurales, se utilizó un modelo de regresión de datos de panel, estimado mediante la librería *linearmodels* de Python.

3.8.1. Elección del modelo

La elección entre el modelo de efectos fijos (FE) y el de efectos aleatorios (RE) es una decisión metodológica crucial en el análisis de datos de panel. Para realizar esta selección de manera objetiva, se utilizó el test de especificación de Hausman.

La hipótesis nula (H_0) del test es que no existe una diferencia sistemática entre los coeficientes de ambos modelos, lo que implica que la suposición de no correlación del modelo RE es válida:

$$H_0 : E(\alpha_i | \mathbf{x}_{it}) = 0 \quad (3.16)$$

Si se rechaza H_0 , se concluye que el modelo RE está sesgado y que el modelo FE es el estimador apropiado. Si no se rechaza H_0 , se prefiere el modelo RE por su mayor eficiencia estadística.

El estadístico de prueba de Hausman (H) sigue una distribución Chi-cuadrado (χ^2) con k grados de libertad, donde k es el número de regresores que varían en el tiempo. Se calcula como:

$$H = (\hat{\beta}_{FE} - \hat{\beta}_{RE})' [\text{Var}(\hat{\beta}_{FE}) - \text{Var}(\hat{\beta}_{RE})]^{-1} (\hat{\beta}_{FE} - \hat{\beta}_{RE}) \quad (3.17)$$

3.8.2. Especificación del modelo

El modelo general de panel busca explicar el valor del SPEI-6 para una estación meteorológica i en un tiempo t .

La ecuación general del modelo de efectos aleatorios es:

$$y_{it} = \mathbf{x}_{it}'\boldsymbol{\beta} + \alpha_i + \varepsilon_{it} \quad (3.18)$$

donde los subíndices representan:

- i : la entidad individual, en este caso, cada una de las 11 estaciones meteorológicas seleccionadas ($i = 1, \dots, 11$).
- t : el período de tiempo, en este caso, cada uno de los 288 meses del estudio ($t = 1, \dots, 288$).

Y las variables del modelo son:

- y_{it} : la variable dependiente, el valor del SPEI-6.
- $\mathbf{x}_{it}$: el vector de variables explicativas (regresores).
- $\boldsymbol{\beta}$: el vector (columna) de coeficientes a estimar.
- α_i : el efecto no observado, específico de cada estación meteorológica i .
- ε_{it} : el término de error idiosincrático.

La especificación completa del modelo estimado, incluyendo todas las variables e interacciones, fue la siguiente:

$$\begin{aligned} \text{SPEI-6}_{it} = & \beta_0 + \beta_1 \text{tiempo}_t + \sum_{s=1}^3 \gamma_s \text{estacion-climatica}_{s,t} + \delta_1 \text{region-geografica}_i \\ & + \sum_{s=1}^3 \theta_s (\text{tiempo}_t \times \text{estacion-climatica}_{s,t}) + \phi_1 (\text{tiempo}_t \times \text{region-geografica}_i) \\ & + \sum_{s=1}^3 \psi_s (\text{estacion-climatica}_{s,t} \times \text{region-geografica}_i) \\ & + \sum_{s=1}^3 \omega_s (\text{tiempo}_t \times \text{estacion-climatica}_{s,t} \times \text{region-geografica}_i) + u_{it} \end{aligned} \quad (3.19)$$

donde $u_{it} = \alpha_i + \varepsilon_{it}$ es el término de error compuesto, y los términos $\text{estacion-climatica}_{s,t}$ y $\text{region-geografica}_i$ son variables dummy para las categorías estacionales climáticas (invierno, primavera, verano, otoño) y regionales geográficas (clusters), respectivamente.

Capítulo 4

Resultados

4.1. Regionalización climatológica de la sequía en Paraguay

Antes de proceder a caracterizar los eventos de sequía y estimar tendencias temporales agregadas mediante el modelado econométrico de panel, resulta indispensable examinar la idoneidad de la división geográfica tradicional del país. Paraguay ha sido históricamente subdividido en dos grandes macroregiones geográficas y administrativas: la Región Oriental y la Región Occidental (Chaco). No obstante, desde una perspectiva climatológica y de balance hídrico (SPEI), esta delimitación dicotómica es puesta a prueba para capturar la variabilidad de los patrones físicos de sequía y los procesos de aridificación espacialmente heterogéneos.

Con el propósito de establecer subregiones climáticas homogéneas de manera objetiva, se aplicó un algoritmo de agrupamiento jerárquico aglomerativo utilizando la distancia de disimilitud euclídea y el criterio de enlace de varianza mínima de Ward sobre la matriz de datos continuos mensuales del índice SPEI-6 para las 11 estaciones meteorológicas seleccionadas durante el período 2000–2023. El preprocesamiento de la base detectó 55 celdas con valores perdidos en las series temporales originales del SPEI-6, los cuales fueron resueltos mediante interpolación lineal temporal antes de proceder con el agrupamiento.

4.1.1. Optimización y selección del número de clústeres

La jerarquía de fusiones consecutivas calculada por el algoritmo de Ward se representa de manera gráfica en el dendrograma de disimilitud de la Figura ?? (Panel A).

Para evitar la discrecionalidad en el corte jerárquico de este dendrograma, se calculó el coeficiente de silueta promedio para un rango operativo de $k \in [2, 5]$ clústeres. El Cuadro ?? expone los resultados de esta optimización espacial, la cual se ilustra además en la curva de optimización de la Figura ?? (Panel B).

Cuadro 4.1: Coeficiente de silueta promedio según el número de particiones (clústeres).

Número de clústeres (k)	Coeficiente de silueta promedio
$k = 2$	0.1350
$k = 3$	0.1235
$k = 4$	0.1174
$k = 5$	0.0991

El coeficiente de silueta promedio alcanza su máximo global para una estructura de $k^* = 2$ clústeres ($s = 0,1350$), indicando que una partición de dos regiones climáticas proporciona la máxima cohesión intra-grupo y la mayor diferenciación inter-grupo. Las particiones alternativas de 3, 4 o 5 grupos muestran un decaimiento progresivo en la calidad de la silueta, justificando estadísticamente la selección de dos subregiones hídricas óptimas a nivel nacional para el período bajo estudio.

4.1.2. Asignación de estaciones meteorológicas y Validación de contigüidad geográfica

Para validar la coherencia climática y física de la regionalización propuesta, se contrastó la asignación temporal derivada del clustering de SPEI-6 con la ubicación geográfica (latitud y longitud) de las estaciones terrestres. La evaluación cuantitativa de las distancias euclídeas de posicionamiento reveló que la distancia geográfica promedio entre estaciones asignadas al mismo clúster (distancia intra-clúster) es de $2,461^\circ$ decimales (aproximadamente 270 km), mientras que la distancia promedio entre estaciones pertenecientes a clústeres distintos (distancia inter-clúster) asciende a los $3,362^\circ$ decimales (aproximadamente 370 km).

Esta diferencia confirma la existencia de una contigüidad geográfica compacta. Como se presenta visualmente en el mapa de la Figura ?? (Panel C), la clasificación basada en la sincronía de la sequía a mediano plazo (SPEI-6) ha particionado el territorio nacional de manera limpia, delimitando dos subregiones climáticas claramente definidas:

1. **Subregión subhúmeda sur-este (Clúster 1):** Integrada por las estaciones de

Caazapá (CAAZ), Pilar (PILAR), Minga Guazú (MINGA), Coronel Oviedo (COVIE) y Capitán Meza (CMEZA). Este bloque representa el sur y este de la Región Oriental, la zona de mayor pluviometría de Paraguay, caracterizada históricamente por balances hídricos promedio superavitarios y una menor inercia a eventos de sequía extrema prolongada.

2. **Subregión semiárida centro-chaco (Clúster 2):** Conformada por las estaciones de Mariscal Estigarribia (MCAL), Gral. Bruguez (GBRU), Luque (LUQUE), Concepción (CONC), San Estanislao (SEST) y Pedro Juan Caballero (PJC). Esta franja geográfica continua se extiende desde el Chaco profundo y húmedo, cruzando el río Paraguay hacia el centro-norte y norte de la Región Oriental. Comparten un régimen de mayor inestabilidad climática, una estación seca invernal muy pronunciada y promedios térmicos elevados que incrementan de forma sistemática la demanda evaporativa.

Esta partición de dos subregiones climáticas óptimas reemplazará de forma sistemática la regional clásica en todos los análisis descriptivos e inferenciales subsiguientes de la investigación, permitiendo examinar el proceso de aridificación con un mayor grado de precisión espacial.

Figura no disponible: ../output/figures/analisis_regionalizacion_sequia.(png|pdf)

Figura 4.1: Resultados de la regionalización climática de la sequía en Paraguay (período 2000–2023): (A) Dendrograma de agrupamiento jerárquico aglomerativo utilizando la distancia de disimilitud de Ward; (B) Optimización del número de clústeres (k) mediante el coeficiente de silueta promedio; (C) Distribución espacial resultante de las estaciones meteorológicas terrestres clasificadas por subregión climática.

Referencias

- Chávez, C. (2023). Análisis de tendencias históricas de la temperatura del aire en el período (1960-2018) en Paraguay. *Kera Yvoty: Reflexiones Climatológicas e Hidrológicas*, 4(1), 54–69.
- Comisión Económica para América Latina y el Caribe (CEPAL). (2014). *La economía del cambio climático en el Paraguay* (Inf. Téc.). Santiago, Chile: Naciones Unidas (CEPAL).
- Gong, X., y Richman, M. B. (1995). On the classification of North American climates. *Journal of Climate*, 8(5), 1157–1188. doi: 10.1175/1520-0442(1995)008<1157:OTCONA>2.0.CO;2
- Grassi, B. (2020). *Estudio del clima Paraguay 2019* (Inf. Téc.). Asunción, Paraguay: Asociación Alter Vida.
- Hausman, J. A. (1978). Specification tests in econometrics. *Econometrica: Journal of the Econometric Society*, 46(6), 1251–1271. doi: 10.2307/1913827
- Masson-Delmotte, V., y cols. (Eds.). (2021). *Climate change 2021: The physical science basis. contribution of working group I to the sixth assessment report of the intergovernmental panel on climate change*. Cambridge, United Kingdom and New York, NY, USA: Cambridge University Press. doi: 10.1017/9781009157896
- McKee, T. B., Doesken, N. J., y Kleist, J. (1993). The relationship of drought frequency and duration to time scales. En *Proceedings of the 8th conference on applied climatology* (Vol. 17, pp. 179–183). Anaheim, CA, USA.
- Mishra, A. K., y Singh, V. P. (2010). A review of drought concepts. *Journal of Hydrology*, 391(1-2), 202–216. doi: 10.1016/j.jhydrol.2010.07.012
- Naumann, G., Podestá, G., Marengo, J., Luterbacher, J., Bavera, D., Acosta Navarro, J., ... Vogt, J. (2023). Extreme and long-term drought in the La Plata Basin: Event evolution and impact assessment until september 2022. *Natural Hazards and Earth System Sciences*, 23(12), 3849–3871. doi: 10.5194/nhess-23-3849-2023
- Pasten, A. (2007). *Análisis de eventos meteorológicos extremos en el Paraguay* (Inf. Téc.). Asunción, Paraguay: Dirección de Meteorología e Hidrología, DINAC.
- Santos, J. F., Pulido-Calvo, I., y Portela, M. M. (2010). Spatial grouping of Portuguese droughts. *Water Resources Management*, 24(14), 3737–3750. doi: 10.1007/s11269-010-9630-y
- Secretaría del Ambiente. (2017). *Tercera comunicación nacional sobre cambio climático de la república del Paraguay* (Inf. Téc.). Asunción, Paraguay: Gobierno del

Paraguay / Secretaría del Ambiente.

- Tsegai, D., Medel, M., Augenstein, P., y Huang, Z. (2022). *Drought in numbers, 2022: Restoration for readiness and resilience* (Inf. Téc.). Bonn, Germany: United Nations Convention to Combat Desertification (UNCCD).
- Velasco, I., Ochoa, L., y Gutiérrez, C. (2005). Sequía, un problema de perspectiva y gestión. *Región y sociedad*, 17(34), 35–71.
- Vera, C., Higgins, W., Amador, J., Ambrizzi, T., Garreaud, R., Gochis, D., ... Zhang, C. (2006). Toward a unified view of the American Monsoon Systems. *Journal of Climate*, 19(20), 4977–5000. doi: 10.1175/JCLI3896.1
- Vicente-Serrano, S. M., Beguería, S., y López-Moreno, J. I. (2010). A multiscalar drought index sensitive to global warming: The standardized precipitation evapotranspiration index. *Journal of Climate*, 23(7), 1696–1718. doi: 10.1175/2009JCLI2909.1
- Ward, J. H. (1963). Hierarchical grouping to optimize an objective function. *Journal of the American Statistical Association*, 58(301), 236–244. doi: 10.1080/01621459.1963.10500845
- Wooldridge, J. M. (2010). *Econometric analysis of cross section and panel data*. Cambridge, MA, USA: MIT Press.
- World Meteorological Organization. (2017). *WMO guidelines on the calculation of climate normals* (Inf. Téc. n.º WMO-No. 1203). Geneva, Switzerland: World Meteorological Organization.